

Messy Customer Sales Data in Data Science (Detailed Note)

১. ভূমিকা

Data Science-এ কোনো analysis বা Machine Learning model তৈরি করার আগে ডেটা নিয়ে কাজ করাই সবচেয়ে গুরুত্বপূর্ণ। কিন্তু বাস্তব জীবনের ডেটা সাধারণত পরিষ্কার থাকে না। বিশেষ করে **Customer Sales Data** — যেমন বিক্রয় রেকর্ড, কাস্টমারের তথ্য, পেমেন্ট ডেটা — এগুলোতে অনেক ভুল, অসম্পূর্ণতা ও বিশৃঙ্খলা থাকে।

এ ধরনের অপরিষ্কার ও অগোছালো ডেটাকে আমরা **Messy Data** বলি।

২. Messy Customer Sales Data কী?

Messy Customer Sales Data হলো এমন ডেটা যা:

- অসম্পূর্ণ (Missing values)
- ভুল ফরম্যাটে (Inconsistent formatting)
- ভুল ডেটা টাইপে (Wrong data types)
- ডুপ্লিকেট (Duplicate records)
- অপ্রয়োজনীয় স্পেস বা টাইপো যুক্ত
- Outlier যুক্ত

অর্থাৎ, সরাসরি ব্যবহারযোগ্য নয়।

৩. বাস্তব উদাহরণ

ধরুন একটি কোম্পানির বিক্রয় ডেটা:

Customer Email		Amount	Date
Rahim	rahim@gmail.com		01-03-2025
		500	01-03-2025
karim		700	2025/03/01

Customer Email	Amount	Date
SALMA salma@gmail.com		March 1, 2025
Rahim rahim@gmail.com	500	01-03-2025

সমস্যা:

- Email ফাঁকা
- Amount ফাঁকা
- Date তিনভাবে লেখা
- Rahim ডুপ্লিকেট
- Customer নামের case mismatch

এটাই একটি **messy dataset**।

৪. Messy Data এর প্রকারভেদ

১. Missing Data (অনুপস্থিত ডেটা)

- ফাঁকা সেল, NULL value, NaN

২. Duplicate Data

- একই ট্রানজ্যাকশন বা কাস্টমার রেকর্ড বারবার

৩. Inconsistent Formatting

- তারিখ ভিন্নভাবে লেখা
- বড় হাতের ও ছোট হাতের অমিল

৪. Wrong Data Type

- Amount সংখ্যা না হয়ে string
- Date text হিসেবে রাখা

৫. Outliers

- 500 টাকার পণ্যের মধ্যে হঠাৎ 500,000 টাকা

৫. কেন Messy Data সমস্যা তৈরি করে?

- Machine Learning model ভুল শিখবে
- Analysis ভুল হবে
- Sales রিপোর্ট ভুল হবে
- Business decision ভুল হবে
- Dashboard বা Revenue report ভুল দেখাবে

সারসংক্ষেপ: ভুল ডেটা → ভুল সিদ্ধান্ত → ক্ষতি।

৬. Data Cleaning কী?

Messy data কে usable format-এ রূপান্তর করার প্রক্রিয়াকে বলা হয় **Data Cleaning** বা **Data Preprocessing**।

বাস্তবে Data Scientist-এর সময়ের প্রায় ৬০-৭০% সময় ডেটা পরিষ্কার করতে যায়।

৭. Data Cleaning এর ধাপসমূহ

১. Missing Value Handle করা

- Drop করা
- Mean/Median দিয়ে fill করা
- Forward/Backward fill

২. Duplicate Remove করা

- একই রেকর্ড বারবার থাকলে drop

৩. Data Type ঠিক করা

- Amount → numeric
- Date → datetime

৪. Standardization

- Customer নাম lowercase বা title case
- Date এক ফরম্যাটে

৫. Outlier Detection

- Z-score
 - IQR method
-

৮. Pandas দিয়ে Cleaning

Python এর **pandas** লাইব্রেরি Data Cleaning এর জন্য সবচেয়ে বেশি ব্যবহৃত।

উদাহরণ:

১. Missing Value Check

```
df.isnull().sum()
```

২. Duplicate Remove

```
df = df.drop_duplicates()
```

৩. String Clean

```
df["Customer"] = df["Customer"].str.strip().str.lower()
```

৪. Numeric Convert

```
df["Amount"] = pd.to_numeric(df["Amount"], errors="coerce")
```

৫. Date Convert

```
df["Date"] = pd.to_datetime(df["Date"], errors="coerce")
```

৯. Clean Data এর সুবিধা

- ✓ Accurate prediction
- ✓ Better visualization
- ✓ Reliable dashboard
- ✓ Correct business decision
- ✓ Faster computation

১০. Customer Sales Data Cleaning এর Real Workflow

১. Data Import
 ২. Initial Inspection (head(), info())
 ৩. Missing Analysis
 ৪. Duplicate Check
 ৫. Format Standardization
 ৬. Outlier Removal
 ৭. Feature Engineering
 ৮. Final Dataset Export
-

১১. E-Commerce Project এ এর ব্যবহার

Messy data ছাড়া:

- Sales analytics
 - Revenue prediction
 - Customer segmentation
 - Recommendation system
- সম্ভব নয়।

বিশেষ করে:

- AJAX দিয়ে dynamic price update
- Dashboard chart
- Monthly revenue report
- Payment analytics

সবকিছু clean dataset এর উপর নির্ভর করে।

১২. Messy Data Handling না করলে কী হবে?

ধরো:

Revenue = 500 + 700 + "Eight Hundred"

- String থাকার কারণে যোগফল হবে না
 - Model crash করতে পারে
 - Graph বা Dashboard ভুল দেখাবে
-

১৩. Data Cleaning vs Data Transformation

Cleaning	Transformation
ভুল ঠিক করা	নতুন feature বানানো
Missing fix	Feature scaling
Duplicate remove	Encoding

১৪. Advanced Topic

- **Categorical Data Type:** Memory efficient
 - **Vectorized Operations:** Loop ছাড়া দ্রুত calculation
 - **Performance Optimization:** Built-in function ব্যবহার
-

১৫. উপসংহার

- Messy Customer Sales Data হলো বাস্তব জীবনের একটি সাধারণ সমস্যা।
- Data Science-এ সফল হতে হলে **ডেটা পরিষ্কার করার দক্ষতা** অত্যন্ত গুরুত্বপূর্ণ।

"Garbage in, Garbage out."

ইনপুট যদি খারাপ হয়, আউটপুটও খারাপ হবে।

- সঠিক Data Cleaning ছাড়া Machine Learning, Analysis, Dashboard — কিছুই নির্ভরযোগ্য হবে না।
- Messy Customer Sales Data সরাসরি বিশ্লেষণের উপযোগী নয়, কিন্তু Data Cleaning প্রক্রিয়ায় এটিকে বিশ্লেষণযোগ্য ও Machine Learning উপযোগী করা যায়।

